

Izveštaj za prvi deo projekta: Klasifikacija muzičkih žanrova

Ime projekta: Prepoznavanje muzičkih žanrova veštačkom neuronskom mrežom

1. Uvod

U ovom radu razvijen je model veštačke neuronske mreže za klasifikaciju različitih muzičkih žanrova na osnovu numeričkih karakteristika svakog uzorka. Korišćen je skup podataka Genres.csv, koji sadrži numeričke deskriptore i odgovarajuće žanrovske oznake.


Cilj projekta je da se model obuči da tačno klasifikuje pripadnost uzorka određenom muzičkom žanru, koristeći date osobine kao ulazne podatke neuronske mreže.

2. Opis skupa podataka

Skup podataka sadrži ukupno **4407 uzoraka**, sa **11 numeričkih atributa**, koji predstavljaju različite statističke i numeričke karakteristike signala.

Ciljna promenljiva je **genre**, koja obuhvata **3 različite klase** (žanra): RnB, Rap, Pop

Distribucija podataka po klasama prikazana je na sledećem histogramu:



3. Predobrada podataka

Ulazne karakteristike su standardizovane korišćenjem **StandardScaler** iz biblioteke sklearn.

Ciljna promenljiva (žanr) je enkodovana korišćenjem LabelEncoder, a zatim pretvorena u kategorijalni (one-hot) format pomoću to_categorical.

Skup je podeljen na:

- **Trening skup** – 80% uzoraka,
- **Validacioni skup** – 10%,
- **Test skup** – 10%,
uz očuvanje raspodele klasa

4. Arhitektura neuronske mreže

Model je razvijen pomoću Keras Sequential API, sa sledećom strukturom:

Ulazni sloj: 11 neurona (broj numeričkih atributa u skupu podataka), Skriveni slojevi:

Dense sloj sa 128 neurona, aktivaciona funkcija: ReLU,

Dropout sloj sa stopom 0.3 (radi smanjenja prenaučivosti),

Dense sloj sa 64 neurona, aktivaciona funkcija: ReLU,

Dense sloj sa 32 neurona, aktivaciona funkcija: ReLU,

Izlazni sloj: Dense sloj sa 3 neurona (broj različitih žanrova u cilju klasifikacije), aktivaciona funkcija: Softmax.

Detalji treniranja:

Kriterijumska funkcija: izabrana je kategorička unakrsna entropija (categorical crossentropy) kao funkcija gubitka. Ova funkcija se često koristi za višeklasnu klasifikaciju jer efikasno meri razliku između stvarnih i predviđenih verovatnosnih distribucija za sve klase. To je standardna funkcija gubitka za višeklasne probleme u savremenim bibliotekama i daje dobre rezultate iz softmax aktivaciju.

- Optimizator: Adam
- Broj epoha: 25
- Veličina batch-a: 16
- Validacioni skup: 10%

Aktivacione funkcije

ReLU (Rectified Linear Unit)

ReLU funkcija se koristi kao aktivaciona funkcija u skrivenim slojevima jer uvodi **nelinearnost** u model, omogućavajući neuronskoj mreži da uči složenije obrasce. ReLU je efikasna u računarskom smislu jer je njena derivacija jednostavna, i ujedno **smanjuje problem zasićenja** (vanishing gradient) koji se javlja kod funkcija poput sigmoid ili tanh.

Softmax

U izlaznom sloju koristi se Softmax funkcija, koja pretvara izlaze mreže u **distribuciju verovatnoće po klasama**. Pogodna je za višeklasne klasifikacione probleme, jer osigurava da su sve vrednosti između 0 i 1 i da njihov zbir daje 1.

Regularizacija

Dropout

Dropout je tehnika **regularizacije** koja nasumično "gasi" (tj. postavlja na nulu) određeni procenat neurona tokom treniranja. Na taj način se **sprečava overfitting**, jer model ne zavisi previše od određenih neurona već uči generalnije obrasce. U ovom projektu je korišćen Dropout sloj sa stopom od 0.3.

Optimizacija

Adam optimizator

Adam (Adaptive Moment Estimation) je jedan od najčešće korišćenih optimizatora jer kombinuje prednosti **RMSProp** i **Momentum** metoda. Prilagođava veličinu koraka (learning rate) za svaki parametar pojedinačno i brzo konvergira ka minimumu funkcije greške. Adam je postao industrijski standard za mnoge zadatke obrade podataka. Adam optimizator je izabran zbog brze konvergencije i adaptivnog podešavanja koraka učenja za svaki parametar. Podrazumevana vrednost `learning_rate=0.001` je korišćena.


Kriterijumska funkcija

Categorical Crossentropy

Za potrebe višeklasne klasifikacije koristi se **categorical_crossentropy** kao kriterijumska funkcija (loss). Ova funkcija meri razliku između stvarne raspodele (izražene one-hot vektorom) i predikcija modela. Ona penalizuje pogrešne predikcije u skladu sa njihovom udaljenošću od stvarne klase i omogućava efikasno učenje.

5. Rezultati treniranja

Model je treniran uz prikaz tačnosti i gubitka po epohama.



6. Evaluacija modela

Evaluacija je vršena na test skupu. Dobijeni su sledeći rezultati:



Postignuta tačnost od 78% ukazuje na solidnu sposobnost modela da razlikuje muzičke žanrove na osnovu numeričkih karakteristika.

```


--- Klasifikacioni izveštaj (TEST SKUP) ---

```

	precision	recall	f1-score	support
Pop	0.33	0.26	0.29	46
Rap	0.82	0.77	0.80	185
RnB	0.70	0.77	0.73	210
accuracy			0.72	441
macro avg	0.62	0.60	0.61	441
weighted avg	0.71	0.72	0.71	441

Razlozi zbog kojih tačnost nije viša uključuju:

- **Sličnost između nekih žanrova** (npr. pop i rock mogu imati slične audio karakteristike),
- **Ograničen broj uzoraka** za treniranje (ukupno svega nekoliko stotina primera),
- **Neuravnoteženost podataka**, iako su klase relativno ravnomerno zastupljene,
- Potencijalna poboljšanja uključuju proširivanje skupa podataka, takođe žanr Pop sadrži manji skup podataka u odnosu na ostala dva.



Hiperparametar Testirane vrednosti

Izabrana vrednost

Obrazloženje

Broj neurona	64, 128 , 256	128	Veća kapacitivnost mreže bez pretreniranja
Dropout stopa	0.2, 0.3 , 0.5	0.3	Balans između regularizacije i performansi
	20, 25 , 50, 100	25	Dovoljno za stabilnu konvergenciju
Broj epoha	16, 32, 16	16	Brže učenje i stabilna optimizacija
Batch size			Zadana vrednost koja
	0.001 (zadano u Adam)	0.001	obično dobro funkcioniše
Learning rate	relu, softmax	relu, softmax	Standard za složene klasifikacije
Aktivacione			Pogodna za
	categorical_crossentropy	categorical_crossentropy	funkcije višeklasne
Loss funkcija			klasifikacije

7. Zaključak

Model potpuno povezane neuronske mreže uspešno klasifikuje muzičke žanrove sa zadovoljavajućom preciznošću.

Arhitektura sa **tri skrivena Dense sloja** i Dropout-om se pokazala stabilnom tokom treniranja.